

Procesamiento de la información en redes bioquímicas

Nuevos Desarrollos en Termodinámica y Física Estadística

Candela Szischik

Resumen

Los sistemas vivos se caracterizan por flujos controlados de materia, energía e información. Estos flujos ocurren a diversas escalas y en particular a nivel molecular. A esa escala es donde se desarrollan los procesos centrales para la vida: desde la detección y la transducción de señales ambientales hasta la lectura y copia de información genética, así como el desencadenamiento de respuestas celulares adaptativas. Tales procesos están coordinados por redes bioquímicas complejas que operan a temperatura ambiente, están fuera del equilibrio e involucran cantidades bajas de diversas moléculas con especificidad de interacción limitada. En este trabajo, se recapitula algunos de los avances realizados en la formalización del flujo de información a través de redes bioquímicas a partir de conceptos provenientes de la teoría de información. Asimismo se discuten las limitaciones de su implementación en estos sistemas y sus implicancias biológicas. En este marco, la optimización de la información se presenta como un posible principio de diseño que, sujeto a restricciones físicas, permitiría predecir arquitecturas confiables de señalización celular y regulación génica construidas a partir de componentes individualmente ruidosos.

La vida a escala molecular

Los sistemas vivos se definen por la presencia de flujos organizados de materia, energía e información, que interactúan en distintas escalas. Es en escala molecular donde ocurren muchos de los procesos más fundamentales para la vida. En este nivel, las células llevan a cabo tareas como la detección y transducción de señales ambientales, la lectura, copia y traducción de información genética, y la activación de respuestas adaptativas que les permiten sobrevivir y responder a su entorno [37]. Ejemplos claros son la transmisión hereditaria de material genético o el llamado dogma central de biología molecular, donde la información contenida en el ADN se transcribe al ARN mensajero y luego se traduce a proteínas. Otro caso emblemático es la información posicional a partir de los niveles de expresión de genes durante el desarrollo embrionario, que permite a los organismos multicelulares formar estructuras corporales precisas y reproducibles. Sin embargo, todos estos procesos ocurren en un contexto intrínsecamente fluctuante.

La vida, a nivel celular y molecular, es un proceso esencialmente estocástico. Las biomoléculas están sujetas a fluctuaciones térmicas producidas por el bombardeo constante de moléculas del entorno circundante. Las células habitan en entornos cambiantes y responden a señales externas variables mediante redes bioquímicas complejas que operan en estas escalas altamente ruidosas. Sin embargo, los sistemas vivos logran prosperar en prácticamente cualquier ambiente [6].

Comprender cómo lo consiguen, a pesar de la estocasticidad, implica estudiar los mecanismos mediante los cuales procesan información y toman decisiones; es decir, cómo una célula selecciona un fenotipo entre varios posibles en respuesta o anticipación a cambios ambientales. Estas decisiones pueden manifestarse en la expresión génica, en cambios morfológicos, en reorganización intracelular o, simplemente, en la elección de mantener el fenotipo actual.

Estos procesos están coordinados por complejas redes de reacciones bioquímicas que operan bajo restricciones físicas y químicas: el consumo limitado de energía, la diversidad

y cantidad restringida de moléculas, o el tiempo y espacio disponibles. Estas condiciones imponen límites severos sobre la precisión con la que puede representarse y procesarse la información molecular, debido a las fluctuaciones térmicas, la baja especificidad de algunas interacciones y la lenta difusión de muchas señales. Por ejemplo, los niveles típicos de ARN mensajero y de proteínas en una célula suelen ser menores a 10000 copias; en estos casos, una variación de apenas unas pocas moléculas debido a una reacción puede representar un cambio proporcionalmente significativo, haciendo que el comportamiento del sistema esté dominado por el azar.

Desde esta perspectiva, la célula puede entenderse como un dispositivo integrado formado por miles de tipos de proteínas, cada una actuando como una máquina molecular de tamaño nanométrico que ejecuta tareas específicas con gran precisión. En una bacteria como *Escherichia coli*, que mide apenas unos micrones, hay presentes varios millones de proteínas correspondientes a unas 4500 clases diferentes, cuya abundancia y dinamismo varían según las necesidades del entorno [1]. Por ejemplo, al detectar la presencia de azúcar, la célula activa la producción de proteínas que permiten transportarlo y metabolizarlo; ante un daño, sintetiza proteínas de reparación. Este comportamiento evidencia un mecanismo de procesamiento de información: la célula monitorea constantemente su ambiente y regula de manera precisa qué genes se activan y a qué ritmo, mediante redes de regulación génica.

Este tipo de procesamiento bioquímico abarca múltiples funciones: detección de señales externas (sensado), codificación de esas señales en concentraciones de moléculas internas, transmisión y decodificación de la información química, memoria celular, copiado de información genética, y la integración de señales para tomar decisiones adaptativas (toma de decisiones). Esta forma de describir los procesos celulares en términos de señales e información es especialmente útil para estudiar circuitos bien caracterizados como la red de quimiotaxis de *E. coli*, que le permite al microorganismo navegar su entorno guiándose por gradientes químicos. En este marco, la célula no solo reacciona, sino que procesa activamente información molecular para decidir su curso de acción, ajustando su fisiología de acuerdo con las condiciones ambientales.

Redes bioquímicas en el contexto de teoría de información

La vida es el resultado de interacciones estocásticas a nivel molecular dentro de las células. Las células son los bloques de construcción de los organismos y exhiben una variedad de formas, tamaños y funciones. Estas propiedades, junto con el comportamiento y el estado de las células, están determinadas por el tipo y el número de proteínas que producen y la información necesaria para sintetizar estas proteínas codificadas en los genes del ADN.

Las células pueden regular la producción de proteínas mediante diversos mecanismos y redes de regulación genética, que involucran procesos químicos y estructurales, así como la interacción entre distintas moléculas. Estos procesos mediante los cuales se controla la expresión de proteínas se denominan en conjunto regulación génica. La regulación de la expresión génica puede ocurrir esencialmente en cada paso de la extracción de la información del ADN: a nivel del empaquetamiento del ADN y modificaciones epigenéticas, en el inicio de la transcripción (proceso de copia del ADN en moléculas de ARN), modificaciones del ARN, traducción (ARN a proteínas) y modificaciones post-traduccionales. Muchos de estos procesos son llevados a cabo mediante proteínas especiales, un ejemplo prominente son los factores de transcripción, que pueden modificar la actividad transcripcional de sus genes objetivo. En un determinado momento, el estado de un organismo vivo no está solamente descrito por su genoma, sino que también por el set de genes regulatorios que están expresados y los niveles de concentraciones de los productos de esos genes.

En este contexto, las interacciones moleculares involucradas en la regulación génica

pueden modelarse como redes de reacciones bioquímicas. Una red de reacciones es un conjunto de reacciones entre $i = 1, \dots, M$ especies químicas, S_i , donde se asumen conocidas la estequiometría y cinética de las mismas. El estado de la red está dado por el número de copias o concentración de cada una de las especies en cada instante de tiempo.

Dependiendo del contexto, la dinámica de estas redes puede ser abordada de distintas formas. Para capturar la estocasticidad intrínseca de las reacciones cuando hay un número bajo de moléculas bajo la hipótesis de sistemas bien mezclados, es posible formular una ecuación química maestra. En la misma consideramos un balance para la probabilidad de encontrar al sistema en un dado estado, definido por un número de moléculas de cada especie, a partir de las posibles transiciones entre estados, dado por las reacciones involucradas. Es por esto que se considera el tiempo continuo y un espacio discreto para la evolución del número de copias [43]. Esta ecuación permite soluciones analíticas en pocos casos, aunque es posible realizar aproximaciones eficientes o algoritmos basados en simulaciones de Monte Carlo [14]. Alternativamente, la aproximación de Langevin permite trabajar con una descripción continua de la dinámica de las concentraciones pero manteniendo la estocasticidad intrínseca; o bien considerando la ley de acción de masas que permite una descripción continua tanto del tiempo como el estado aunque sólo es posible incorporar ruido extrínseco. Si bien el uso de una u otra descripción matemática dependerá del contexto, en todos los casos se tiene en cuenta una característica esencial de estos procesos biológicos, la naturaleza estocástica asociada a las limitaciones físicas del sistema.

Si consideramos procesos biológicos regulatorios, es necesario complementar a la red con anotaciones adicionales. Algunas especies actuarán como la entrada -input- de la red, como señales externas de nutrientes, hormonas u otras moléculas de señalización. Por simplicidad, consideremos que S_1 constituye el *input*, con una concentración $x(t)$. La dinámica de entrada impuesta externamente $x(t)$ genera una respuesta de la red. Generalmente, nos enfocamos en un número pequeño de especies S_M con alguna relevancia biológica, que interpretaremos como la salida o *output* de la señal, cuya concentración la denotaremos como $y(t)$. Dada la naturaleza estocástica de la red, incluso dada una trayectoria determinista del *input* $x(t)$, la trayectoria del *output* es una variable aleatoria extraída de una distribución $P(y(t)|x(t))$.

Nos interesa estimar cómo es la dependencia de la salida con la entrada, considerando que la codependencia está íntimamente relacionada con el concepto de información. Una posibilidad es estudiar correlaciones o covarianzas entre las variables de entrada y salida. No obstante, estas cantidades sólo capturan dependencias lineales y no distinguen adecuadamente entre distintos tipos de ruido o relaciones funcionales no lineales. En particular, dos variables pueden presentar covarianza nula y aun así estar fuertemente relacionadas estadísticamente. Más aún, la covarianza no cuantifica directamente cuán bien puede inferirse la entrada a partir de la salida en presencia de fluctuaciones. Por esta razón, resulta natural recurrir a herramientas de teoría de la información, donde la información mutua proporciona una medida general de dependencia estadística entre entrada y salida, independiente de la naturaleza lineal o no lineal de la relación entre ambas y capaz de incorporar de manera explícita los efectos del ruido biológico. Desde un punto de vista teórico, la distribución $P(y|x)$ puede ser calculada, aproximada o sampleada usando los modelos matemáticos de las redes; en lo experimental, la distribución puede ser estimada midiendo pares de respuesta *input-output*.

Podemos pensar entonces, en términos de la red:

$$S_1 \rightarrow \{S_i\}_{i=2, \dots, M-1} \rightarrow S_M$$

o bien, si lo pensamos como un problema de transmisión de información:

$$\text{input } X \sim P_X(X) \xrightarrow[\text{channel}]{P(Y|X)} \text{output } Y$$

En este formalismo, el canal, concepto central en la teoría de información de Shannon, mapea estocásticamente alguna señal X extraída de la distribución $P_X(X)$ en *outputs* Y a través de la probabilidad condicional $P(Y|X)$ que captura el ruido y posibles transformaciones o distorsiones en la transmisión de la señal producto de la red de reacciones químicas.

La fidelidad del mapeo de la señal de entrada a la salida puede ser cuantificada mediante la **información mutua** (I), una cantidad no negativa medida en bits, definida como:

$$\begin{aligned} I(X; Y) &= \int P(Y, X) \log_2 \frac{P(Y, X)}{P_Y(Y)P_X(X)} dX dY \\ &= \int P(Y | X)P_X(X) \log_2 \frac{P(Y | X)}{P_Y(Y)} dX dY \\ &= \int P(Y | X)P_X(X) \log_2 \frac{P(Y, X)}{P_Y(Y)P_X(X)} dX dY \end{aligned} \quad (1)$$

donde $P_Y(Y) = \int p(Y|X)P_X(X)dX$. La información mutua es una medida universal de dependencia estadística entre dos variables aleatorias X e Y . La misma describe la información en la distribución de probabilidad de una variable aleatoria X sobre la distribución de otra variable Y , es decir la reducción de incertidumbre en una variable aleatoria X luego de observar la otra Y , lo que es equivalente a la entropía relativa de la distribución conjunta de X e Y en relación al producto de sus marginales. I da una medida de la asociación o correlación entre las dos variables y refleja la reducción de incertidumbre (o lo que es lo mismo, la información ganada) para Y cuando X es conocida. La información mutua es cero si y sólo si las dos variables son independientes, es decir que la probabilidad conjunta es factorizable. A su vez, también es simétrica en X e Y .

La cantidad resultante se mide en bits y es esencialmente el logaritmo del número de estados de entrada (X) que producen salidas (Y) distinguibles dado el ruido del canal.

La información mutua tiene a su vez algunas propiedades particularmente interesantes al estudio de problemas biológicos. En primer lugar, está definida para cantidades continuas como discretas, a su vez, es invariante ante reparametrizaciones, es decir si f, g son funciones inyectivas $I(x, y) = I(f(x), g(y))$. En un contexto biológico, esto representa una gran ventaja: los experimentos suelen reportar, por ejemplo, intensidades o logaritmos de intensidades en los chips de microarrays o en la clasificación celular activada por fluorescencia, y existe un debate considerable sobre cómo normalizar, transformar o interpretar estos datos antes de cualquier análisis, o cómo las propias células interpretan sus concentraciones internas de factores de transcripción. Esta característica de la información mutua es importante porque otras medidas estadísticas de correlación, como los coeficientes de correlación, dependen de transformaciones de los datos. A su vez, la medida de información obedece a la desigualdad del procesamiento de datos. Supongamos que y depende de x y que w depende de y pero (pero no directamente de x), de una forma probabilística, es decir que se puede pensar como un proceso $x \rightarrow y \rightarrow w$. En ese caso $I(x, w) \leq I(x, y)$, es decir que la información o bien se pierde o se mantiene en cada nivel ruidoso de la transmisión, pero nunca es creada espontáneamente.

Shannon demostró que cualquier dependencia estadística -cuando se aprovecha cuidadosamente mediante el diseño de esquemas de codificación y decodificación que incorporan la información en las entradas del canal X y la recuperan desde las salidas del canal Y - puede utilizarse, bajo condiciones adecuadas, para transmitir información a través de un canal ruidoso sin errores. La información no depende sólo del canal, representado por la distribución condicional $P(Y|X)$, sino también de la distribución de la señal que se desea transmitir a través del mismo. Dado un canal, es posible encontrar la distribución de entrada para la cual se maximiza la información mutua, la resultante información transmitida máxima se denota como la capacidad del canal $C = \max_{P_X(X)} I(X; Y)$.

Si pensamos que las variables X e Y son trayectorias de concentraciones, las mismas tendrán una duración T , por lo que la información mutua será extensiva en T . En este contexto tiene sentido definir la tasa de información en bits por segundo definida como el límite $R = \lim_{T \rightarrow \infty} I(x(t); y(t))/T$. Calcular o estimar esta cantidad es en general intratable ya que requiere integrar sobre distribuciones de dimensionalidad alta en el espacio de trayectorias, a menos que se cuente con un fuerte conocimiento previo.

Hay algunos pocos ejemplos, como la quimiotaxis, donde el rendimiento real de una red ha sido cuantificado directamente a partir de datos y, al mismo tiempo, calculado mediante un modelo mecanístico con una concordancia excelente. En ese sistema, la tasa de información representa una métrica de rendimiento escalar, natural y libre de supuestos. Esto abre una gran cantidad de interrogantes acerca de cómo se ve afectado el rendimiento por cambios en la topología o en los parámetros de la red, cuánta energía se consume para mantener esas tasas de información; o bien si la evolución ha moldeado esta red en el sentido de optimizar la codificación de estímulos químicos, así como la robustez de la misma frente a fluctuaciones externas. Estas preguntas han sido estudiadas en sistemas reales donde es posible cuantificar el flujo de información en estas redes, como en la mencionada quimiotaxis, así como mecanismos de resistencia a antibióticos o redes de señalización en levaduras. Algunos ejemplos son la quimiotaxis, mecanismos de resistencia a antibióticos así como redes de regulación génica en bacterias; redes de señalización en levaduras y otros organismos eucariotas, así como también en patrones de desarrollo.

Límites termodinámicos fundamentales

En definitiva las redes de reacciones bioquímicas son sistemas físicos sujetos a los límites fundamentales de la termodinámica, los cuales se vuelven aún más restrictivos cuando se opera a escala nanométrica y a temperatura ambiente.

Procesamiento de información fuera del equilibrio

Si toda información debe apoyarse en un sistema físico, las operaciones lógicas irreversibles -donde hay una pérdida de información- corresponden a transformaciones irreversibles de los sistemas de apoyo. Según Landauer, el proceso de borrar información implica una disipación de energía en forma de calor [23]. En particular, el límite de Landauer determina la energía mínima necesaria para borrar un bit es de $k_B T \ln(2)$. Si bien este límite es irrelevante para sistemas electrónicos, ya que operan en costos energéticos muy superiores al mismo, los sistemas celulares podrían acercarse bastante, por ejemplo, en procesos de copiado de polímeros [29] o en redes enzimáticas tipo *push-pull*, que teóricamente podrían copiar información con un 99 % de precisión, consumiendo una energía que está solo a un orden de magnitud del límite de Landauer [28]. Además, el gasto energético puede servir para mantener a estas redes fuera del equilibrio termodinámico, lo que les permite operar en regímenes especiales que favorecen un procesamiento confiable de la información o bien tener una ventaja funcional, por ejemplo en términos de la especificidad y fidelidad del sensado mediante mecanismo de proof-reading, reducción del ruido en la expresión génica o mayor sensibilidad o precisión temporal [16, 15, 46]. Por ejemplo, en sistemas en equilibrio la precisión del sensado está fundamentalmente limitada por el número de receptores, debido a un compromiso impuesto por el teorema de fluctuación-disipación entre la reducción del ruido extrínseco e intrínseco, de modo que las redes de señalización río abajo no pueden mejorar la estimación de la señal. En sistemas en equilibrio la señal es transmitida aprovechando la energía de unión ligando-receptor, que se utiliza para propagar la información hacia la red aguas abajo. Sin embargo, el balance detallado implica que la interacción entre el receptor y el readout también retroalimenta la unión ligando-receptor, pertur-

bando la señal de entrada y generando correlaciones entre el ruido extrínseco e intrínseco. En contraste, la disipación de energía permite romper este compromiso, posibilitando la integración temporal del estado del receptor y una transducción más eficiente de la señal, como ocurre en redes fuera del equilibrio basadas en motivos *push-pull*, las cuales requieren disipar al menos del orden de $k_B T$ por receptor para superar dicho límite. En este sentido, los mecanismos de sensado en equilibrio y fuera del equilibrio pueden interpretarse como estrategias alternativas de señalización, seleccionadas bajo diferentes restricciones físicas y biológicas. En particular, cuando la precisión del sensado es crítica pero el número de receptores disponibles en la membrana es limitado, los mecanismos fuera del equilibrio se vuelven esenciales, ya que permiten extraer más información por receptor mediante la integración temporal de la señal. De este modo, el consumo de energía no solo permite superar limitaciones termodinámicas fundamentales, sino también compensar restricciones espaciales, incrementando la cantidad efectiva de mediciones que cada receptor puede realizar [16].

Estocasticidad ante un número bajo de copias

La expresión y regulación génica son procesos complejos que incluyen numerosos componentes y pasos de reacción, abarcando varias escalas de tiempo y concentración. Las redes bioquímicas operan a bajas concentraciones de moléculas, imponiendo así restricciones en las computaciones en estos sistemas. Asimismo el proceso de síntesis molecular está sujeto a fluctuaciones en el ambiente celular, la expresión génica es un proceso estocástico que resulta en outputs ruidosos y variabilidad a través de las poblaciones. Esto implica que la presencia de ruido se da tanto a nivel de la entrada, aunque también es intrínseco a la red misma, o bien extrínseco, considerando la variabilidad entre réplicas de un mismo sistema.

El procesamiento de información a esta escala involucra procesos físicos que se dan a concentraciones bajas. Por ejemplo, las células miden la concentración de sustancias químicas en el ambiente mediante receptores en su superficie con alta precisión. Por ejemplo, la bacteria *E. coli* puede detectar 3.2 nM del atrayente aspartato, lo que corresponde a solo alrededor de 3 partículas del atrayente en el volumen de la célula [24], o bien células eucariotas individuales como la levadura *S. cerevisiae* son bien conocidas por medir y responder a gradientes extremadamente suaves de señales químicas [31].

Sin embargo, estas medidas están inevitablemente atravesadas por el ruido que proviene tanto de la llegada estocástica de moléculas de ligando al receptor por difusión así como de la unión también estocástica del ligando al receptor. Las redes bioquímicas que transmiten la información sobre la concentración de ligando desde la superficie de la célula hacia su interior a menudo deben filtrar este ruido extrínseco tanto como sea posible. Cuán precisa es la medición de la concentración de ligando c ha sido bastante estudiada [3, 15]. La precisión por la que un detector microscópico de tamaño a (el receptor en la membrana) puede estimar una concentración media $\bar{c}$ de una sustancia química difusible (un ligando con una constante de difusión D) en su entorno local, está estimado por el límite de Berg-Purcell. [2]:

$$\left(\frac{\Delta c}{\bar{c}} \right) \gtrsim \frac{1}{Da\bar{c}T}$$

donde T es el tiempo de integración de la señal. Este resultado aplica cuando el sensor es una única molécula receptora, por lo que a tiene dimensiones moleculares, de manera que es toda la célula, de forma tal que $a \sim 1\mu m$. Otros autores revisitaron este límite teniendo en cuenta efectos espaciales, las reacciones involucradas o bien optimizando el tiempo de integración [3, 22]. La premisa de estos estudios se basa en que la concentración es estimada a partir de la ocupación media de receptores en un tiempo de integración T dado por la red río abajo, invirtiendo la relación *input-output*. Endres y Wingreen [11] y Mora y

Wingreen [27] mostraron que estimaciones de máxima verosimilitud considerando las series temporales de ocupación de receptores pueden mejorar esta estimación. Los receptores que minimizan el tiempo que están ocupados son los que obtienen mayor precisión. Asimismo no es claro cómo mecanísticamente las células pueden sensar y responder exclusivamente a la duración de los intervalos donde el receptor está libre. De todas formas, todas las reversiones agregan prefactores de orden 1, por lo que el límite de Berg-Purcell sigue siendo válido en términos generales. Si bien el límite estuvo motivado por el problema de detectar señales extracelulares en la superficie de la célula, su importancia más amplia proviene del hecho de que también se aplica a la detección intracelular, por ejemplo, en la unión de factores de transcripción a *enhancers* o promotores en el ADN [19].

El error de sensado está fundamentalmente limitado por el ruido extrínseco a la célula. El ruido representado por el límite de Berg-Purcell representa un tipo de ruido de la entrada que no puede ser removido simplemente al aumentar la ganancia de la red, dado que se amplificaría junto con la señal. Sin embargo, puede reducirse al tomar múltiples muestras independientes, ya sea aumentando el número de receptores, o bien tomando más medidas por receptor en el tiempo o mediante promediado espacial o temporal, este último requiriendo energía y moléculas que registren estados pasados del receptor [15, 16].

En ese sentido, si las redes bioquímicas son los dispositivos de procesamiento de información en escala molecular, y como cualquier dispositivo, requieren de recursos para su constitución y funcionamiento. Se necesitan componentes para construir la red, se requiere espacio para alojarlos, se necesita tiempo para procesar la información y se requiere energía para fabricar los componentes y operar la red. Estos recursos limitan el diseño y el rendimiento de cualquier red bioquímica. Sin embargo, no está claro qué recursos son indispensables, limitando así fundamentalmente el rendimiento de la red, y qué recursos podrían ser contrapuestos entre sí. Govern y Ten Wolde [17] encontraron que la capacidad de detección de las redes bioquímicas depende de tres clases fundamentales de recursos: los receptores y su tiempo de integración, las copias de moléculas río abajo y la energía. Estos recursos no pueden compensarse entre sí, ya que cada uno impone un límite propio a la precisión, aunque sí existen compromisos dentro de cada categoría. A partir de esto surge un principio de diseño: en un sistema óptimo, todos los recursos deben ser igualmente limitantes, evitando excesos y desperdicio. Este principio de asignación óptima de recursos se observa, por ejemplo, en el sistema de quimiotaxis de *E. coli*, lo que sugiere que la evolución no solo optimiza la estructura de estas redes, sino también cómo distribuyen eficientemente sus recursos para lograr una detección precisa.

Por otro lado, el procesamiento de información está condicionado por otras fuentes de ruido más allá del límite de Berg-Purcell. El ruido intrínseco que proviene de la ocurrencia aleatoria de reacciones químicas puede contribuir a una varianza Poissoniana o super-Poissoniana (ráfagas de eventos). Un ejemplo es la expresión génica en ráfagas, aún cuando a tasas constantes para síntesis y degradación del ARNm, que da lugar a múltiples copias de proteína, la distribución estacionaria de esta última será sobredispersa (es decir que el factor de Fano, definido como la varianza al cuadrado sobre la media, es mayor a 1).

Asimismo, otras fuentes de ruido pueden surgir de la estocasticidad térmica por la cual sistemas moleculares transicionan entre distintos estados conformacionales o de actividad, como puede ser la apertura de los canales moleculares [4].

Por último, también existe una fuente de ruido extrínseca asociada a la variabilidad entre réplicas, por ejemplo en la variabilidad célula a célula debido al ruido en sus condiciones iniciales, geometría, parámetros o entornos fluctuantes [33, 10].

Limitada especificidad de las interacciones moleculares e interferencia

Las redes bioquímicas están definidas a través de interacciones moleculares que no son infinitamente específicas: con una probabilidad baja pero no nula, pueden ocurrir inter-

acciones entre moléculas no cognadas, incluso si estas interacciones resultan perjudiciales para la función. Aún así, la vida depende de que se den las interacciones necesarias a pesar de la baja especificidad y evitar interacciones no deseadas, por lo que es de interés estudiar cuáles son los mecanismos compensatorios de estas limitaciones. Uno de estos mecanismos ampliamente extendido es el consumo de energía.

El correcto funcionamiento de la síntesis de proteínas depende de la habilidad de leer el código genético con pocos errores. Se estima que la frecuencia máxima a la que se inserta un aminoácido similar pero incorrecto en la síntesis de una proteína es de 1 en 10^4 , por lo que los niveles de discriminación superiores a esta cota deben mantenerse en los pasos de reconocimiento de los aminoácidos. Cómo se logran tasas de error tan bajas resulta difícil de explicar únicamente a partir de diferencias de energía libre entre productos correctos e incorrectos. Este problema se resuelve mediante mecanismos fuera del equilibrio, como la corrección cinética (kinetic proofreading), que permiten reducir los errores más allá de los límites impuestos por la termodinámica en equilibrio. Estos mecanismos utilizan energía para introducir pasos adicionales en las rutas de reacción, aumentando la discriminación entre sustratos correctos e incorrectos y disminuyendo así la probabilidad de incorporación errónea [21].

Si bien el efecto de la baja especificidad ha sido ampliamente estudiado a nivel de motivos individuales, la interferencia a nivel global en redes de regulación está comenzando a ser analizada [13, 18]. La especificidad en el reconocimiento molecular en la regulación transcripcional se origina en la interacción de unión entre las proteínas reguladoras, los factores de transcripción y las secuencias de ADN reguladoras, llamados sitios de unión. Si bien cada factor de transcripción se une preferentemente a unas determinadas secuencias reguladoras de ADN, la especificidad es limitada, por lo que estos factores pueden unirse a otros sitios no cognados. Esto no sólo afecta la regulación del gen de interés al reducir la concentración disponible del factor de transcripción, sino que también el sitio no cognado puede corresponder a una región reguladora de otro gen, por lo que induce así una regulación espuria. Esto sugiere que la interferencia puede ser un problema global, más aún si consideramos el nivel de complejidad de estas redes regulatorias.

Al considerar un modelo biofísico para estas interacciones cruzadas, los autores encuentran una expresión para la interferencia en función de ciertos parámetros biológicamente relevantes como el número de genes, cuántos de estos están co-expresados, así como la similitud entre los sitios de unión. Los autores encuentran distintos regímenes de interferencia según estos parámetros, donde una concentración no nula que minimiza este efecto existe solo cuando los sitios de unión son suficientemente distinguibles y el número de genes activados no es extremo. Más aún, encuentran que esta medida de similitud entre sitios impone una cota superior al número de genes que pueden ser regulados efectivamente. Asimismo, hallan una cota para la interferencia, encontrando que aún para organismos con pocos genes (5000 genes) y en una situación realista de genes co-activos y similitud entre sitios, la interferencia es del orden de 25 %, implicando que casi un cuarto de los genes en algún momento estará en un estado de regulación erróneo. Considerando que organismos eucariotas pueden tener hasta 20000 genes el efecto global de la interferencia impone un límite serio en la regulación por lo que explicaría el surgimiento de otros mecanismos de regulación que pueda compensar estos efectos. En ese sentido, la cooperatividad y la regulación combinatoria con múltiples factores de transcripción permitirían reducir el efecto no deseado [13]. Asimismo, otro mecanismo biofísico compensatorio es el uso activo de la cromatina, el empaquetamiento físico del ADN por nucleosomas y otras proteínas asociadas, en gran medida exclusivas de los eucariotas [30]. La cromatina puede obstruir físicamente los sitios de unión o inhibir el inicio de la transcripción bloqueando el ensamblaje del complejo de preiniciación, sin embargo hay un costo energético asociado a la remodelación de la misma mediante factores pioneros. El esquema de regulación combinatorio entre factores

de transcripción y pioneros reduce, a escala global, la presión por lograr una alta especificidad en las interacciones regulatorias y permite un aumento del tamaño del genoma con un impacto mínimo en el error de expresión.

Es interesante señalar que la regulación basada en la cromatina, así como la existencia de promotores o *enhancers* en el ADN son innovaciones evolutivas de las células eucariotas. Si bien no podemos afirmar que la cromatina haya surgido con el propósito de regular genes, pareciera que las evoluciones posteriores expandieron su capacidad para hacerlo, por lo que también ha permitido la existencia de genomas considerablemente grandes en eucariotas. Asimismo, la baja especificidad de los factores de transcripción puede tener una ventaja evolutiva en términos de su capacidad para evolucionar durante episodios transitorios de adaptación, aunque en última instancia podría ser seleccionada en contra [12].

En esa dirección, los modelos de regulación en el equilibrio fallan en capturar la regulación génica fuera de los procariotas. Modelos fuera del equilibrio parecieran recuperar la alta especificidad de la regulación génica, que emerge como una propiedad colectiva [18].

Motivos bioquímicos para un óptimo procesamiento de información

Considerando los límites fundamentales desarrollados en la sección anterior, podemos hipotetizar que la forma en la que las redes bioquímicas se interconectan puede ser tal que puedan procesar y transmitir información de forma fiable. En esta sección nos proponemos abordar distintos enfoques teóricos sobre el tema, primero los resultados estáticos basados en aproximaciones de ruido pequeño y luego resultados dinámicos, centrados mayoritariamente en el formalismo del canal Gaussiano.

Resultados estáticos

Partiendo del motivo más sencillo, $X \rightarrow Y$ podemos estimar cuánta información fluye de un nodo X a un nodo Y en el estado estacionario. El flujo de información podría ser por ejemplo, cómo la concentración del regulador x (típicamente un factor de transcripción) afecta a un target y , por ejemplo, en sus niveles de expresión estacionarios. Una forma de caracterizar el flujo en modelos biofísicos simples es construir el mapeo de las medias de input/output y el ruido asociado, dado por $\sigma_y^2(x)$.

En el contexto de redes bioquímicas, un caso de estudio es la regulación transcripcional, donde los factores de transcripción regulan la expresión génica al unirse a los sitios de unión del ADN. Los factores de transcripción pueden unirse y desunirse de los sitios de unión del ADN; cuando el sitio está ocupado, la expresión génica ocurre a una cierta tasa constante.

El objetivo es entonces estudiar la fiabilidad de un elemento regulatorio simple, es decir que la capacidad de un simple factor de transcripción activador o represor de controlar los niveles de expresión de los genes río abajo. En el lenguaje de la teoría de la información podemos conceptualizar este tipo de control considerando la concentración c del factor de transcripción es la entrada o *input* y el nivel de expresión g del gen es la salida - *output*- de este canal. El elemento regulatorio en sí se parametriza por el *kernel* de entrada-salida $P(g|c)$, es decir la distribución de posibles *outputs* g dado que el valor del *input* está fijo en algún nivel c . Para este *kernel* es posible computar la máxima información I transmitida, definida en la Eq.(1), y así examinar cómo la capacidad depende de las propiedades del *kernel*. El mismo está determinado por las propiedades del sistema, es decir la biofísica de la interacción del factor de transcripción y el ADN, así como los mecanismos asociados a la transcripción y traducción del gen g . Esta distribución tiene una contraparte determinista que la función $g = g(c)$, típicamente no lineal ¹. Por otro lado, la

¹En general lo que miden los experimentos es la concentración media sobre la distribución de *outputs*

distribución de la concentración del factor de transcripción $p_{TF}(c)$ que la célula usa durante su tiempo de vida, no es una propiedad del proceso regulatorio $c \rightarrow g$ directamente, sino que incluye otros procesos dentro del entorno interno de la misma; la distribución $p_{TF}(c)$ puede pensarse como la representación del mundo externo y los estados internos por los cuales la célula responde al modular los niveles de expresión de g . Ambas distribuciones definen la distribución de probabilidad conjunta $p(c, g)$ y consecuentemente la información mutua I entre el *input* y *output*. Maximizar esta cantidad implica una correspondencia entre las dos distribuciones, si bien ambas son internas a la célula, por el estado de los experimentos, se considera $P(g|c)$ como dada y se busca cuál es la distribución $p_{TF}(c)$ que optimice I . Aún si la hipótesis de que el sistema no maximiza la información, la distribución óptima del *input* $-I[P(g|c), p_{TF}^*(c)]$ puede pensarse como una cota superior para la información transmitida por el sistema [35].

Si bien en general es difícil tener expresiones analíticas para el cálculo de la información mutua es este sistema, un primer abordaje es posible al considerar la aproximación de ruido pequeño. El nivel de expresión dado una concentración del factor de transcripción c fija tiene un valor medio $\bar{g}(c)$ que se puede graficar como la relación input-output de la Fig. 1. Supongamos que las fluctuaciones alrededor de la media son gaussianas, con una varianza $\sigma_g^2(c)$, que a su vez depende también de la concentración del factor de transcripción. Esto implica que la distribución $P(g|c)$:

$$P(g|c) = \frac{1}{\sqrt{2\pi\sigma_g^2(c)}} \exp \left\{ -\frac{[g - \bar{g}(c)]^2}{2\sigma_g^2(c)} \right\}. \quad (2)$$

Bajo la aproximación de ruido pequeño, es posible expandir las integrales de la expresión de la información mutua (eq. 1) como series de potencias de σ_g alrededor de la media $\bar{g}$:

$$I(c; g) = - \int d\bar{g} \hat{P}_{exp}(\bar{g}) \log_2 \hat{P}_{exp}(\bar{g}) - \frac{1}{2} \int d\bar{g} \hat{P}_{exp}(\bar{g}) \log_2 [2\pi e \sigma_g^2(\bar{g})] + \dots \quad (3)$$

donde descartamos los términos superiores de la expansión, $\hat{P}_{exp}(\bar{g})$ es la distribución de probabilidad para los niveles medios. Podemos pensar esta distribución como la que generaría la célula en ausencia de ruido, es decir:

$$\hat{P}_{exp}(\bar{g}) \equiv \int dc P_{TF}(c) \delta[\bar{g} - \bar{g}(c)] = P_{TF}(c = c_*(\bar{g})) \left| \frac{d\bar{g}}{dc} \right|_{c=c_*(\bar{g})}^{-1} \quad (4)$$

donde $c_*(\bar{g})$ es la concentración del factor de transcripción para la cual el nivel de expresión medio es $\bar{g}$, y por $\sigma_g(\bar{g})$ se entiende que es $\sigma_g(c)$ evaluada a $c = c_*(\bar{g})$.

Entonces nos preguntamos cuál es la distribución de las concentraciones del factor de transcripción $P_{TF}(c)$ que maximiza la transmisión de información $I(c; g)$. Bajo la aproximación de ruido pequeño, se ve de la eq. 3 que la información puede escribirse en función de la distribución de los niveles de expresión $\hat{P}_{exp}(\bar{g})$, y a su vez de la eq. 4 se ve que esta distribución es una transformación invertible de la distribución de *inputs* $P_{TF}(c)$. Por lo tanto, es posible dar la optimización de la información ajustando $\hat{P}_{exp}(\bar{g})$, cuya solución es:

$$\hat{P}_{exp}^*(\bar{g}) = \frac{1}{Z} \frac{1}{\sigma_g(\bar{g})} \quad (5)$$

$$Z = \int d\bar{g} \frac{1}{\sigma_g(\bar{g})} \quad (6)$$

$\bar{g}(c) = \int dg g P(g|c)$. Nuevos desarrollos experimentales como citometría de flujo o microscopía a célula única permite ver la expresión a través del tiempo y sobre una población, estudiando así las fluctuaciones $\sigma_g^2 = \int dg (g - \bar{g})^2 P(g|c)$

Este resultado muestra que una regulación efectiva requiere del uso preferencial de las señales que tienen alta fiabilidad o varianza baja, es decir que $\hat{P}_{exp}(\bar{g})$ es grande cuando σ_g es chico. La máxima información transmitida se obtiene reemplazando esta distribución óptima en la eq. 3, resultando $I^*(c; g) = \log_2(Z/\sqrt{2\pi e})$. La ecuación 5 conecta la distribución óptima de los niveles de expresión del output con los niveles de varianza de esa misma cantidad, mostrada a lo largo de la vida de la célula a medida que responde a variaciones en su entorno.

En la medida en que la aproximación de ruido pequeño sea aplicable, los datos sobre la varianza en función de la expresión media son suficientes para calcular la capacidad máxima de información; afortunadamente, la varianza de un producto génico como función de su nivel medio de expresión es precisamente la magnitud de interés en la mayoría de los experimentos sobre ruido transcripcional [36]. Es interesante notar que los detalles de la relación entre la entrada y salida, es decir cómo es modelada la regulación transcripcional, por ejemplo en términos de la cooperatividad, no son relevantes, salvo que impacten en el ruido, y más aún, no es necesario conocer cuáles son las fuentes microscópicas del ruido que contribuyen en determinada medida al ruido total observado.

Dado que la información óptima puede aproximarse conociendo el ruido del output, es de interés medir la contribución del ruido intrínseco. Es posible medir la contribuciones intrínsecas y extrínsecas del ruido en células únicas a partir de circuitos sintéticos [10]. Elowitz y colegas cuantificaron la varianza intrínseca de los niveles de expresión dentro una población de bacterias como función de los niveles medios de expresión. Sus resultados pueden resumirse en la siguiente expresión $\sigma_g^2(\bar{g}) = a\bar{g} + b\bar{g}^2$, donde la expresión media está normalizada, y las constantes $a = 5 - 7 \times 10^{-4}$, $b = 3 - 10 \times 10^{-3}$. A lo largo de gran parte del rango dinámico, la aproximación de ruido pequeña resulta válida, por lo que es suficiente para calcular la tasa óptima de transmisión de información, obteniéndose que $I^*(c; g) \sim 3,5$ bits.

Este resultado indica que, en lugar de estar limitados a un funcionamiento tipo prendido/apagado, los sistemas de control transcripcional podrían, en principio, especificar $2^{I^*} \sim 10 - 12$ niveles distinguibles de expresión génica. De todas formas, esta capacidad está calculada en un sistema sintético, por lo que no es claro si está disponible para su uso para la célula en un entorno natural. Sin embargo, el cálculo sí demuestra que los valores óptimos de transmisión de información derivados de datos reales son mayores que 1 bit, pero quizá lo suficientemente pequeños como para imponer restricciones significativas sobre la función regulatoria.

Estas predicciones también se ajustan a experimentos de desarrollo de embriones de la mosca *Drosophila*. Durante el desarrollo, las células deben determinar su posición espacial para activar la correcta expresión de los genes *gap*. Para ello utilizan gradientes de concentración de factores de transcripción, como Bicoid (Bcd), que varían a lo largo del embrión. Este factor regula la expresión de los genes *gap* como el Hunchback (Hb), siempre condicionado por el ruido biológico. En este sentido, es posible estudiar este problema en términos de como es la transmisión de información de los factores de transcripción al nivel de expresión de estos genes *gap*, considerando a Bicoid como entrada y a los genes *gap* como salida. A partir de datos del perfil de concentraciones de Bcd y Hb así como la varianza a lo largo de células en distintas posiciones del embrión [19], es posible calcular la capacidad máxima de información del sistema, entendiendo que maximizar la información entre Bcd y Hb maximiza la información posicional que conlleva los niveles de expresión de Hunchback (Fig.1 b). Bajo las consideraciones de ruido pequeño, asumiendo una respuesta estacionaria para la distribución $P(g|c)$, es posible utilizar el formalismo mencionado anteriormente, obteniéndose que $I^*(c; g) = 1,7$ bits.

En un enfoque más amplio, en lugar de pensar que cada gen *gap* tiene su propio perfil espacial, podemos considerar que los niveles de expresión de todos estos genes en

conjunto constituyen un código para la posición de cada célula. En ese sentido, podemos pensar cuántos genes son necesarios para codificar una posición única entre las $N \sim 100$ filas de núcleos a lo largo del eje del embrión. Si la regulación de Hunchback dada por Bicoid es representativa de lo que ocurre en este nivel de la cascada de desarrollo, entonces cada 'letra' del código está limitada a menos de dos bits ($I^* = 1,7\text{bits}$) de precisión, dado que $\log_2(N)/I^* = 3,9$, este código necesita al menos cuatro letras. Es interesante notar que hay cuatro genes *gap* conocidos- *hunchback*, *kruppel*, *giant* y *knirps*- que son los que proporcionan la lectura inicial de los gradientes de los factores de transcripción a lo largo del embrión. Si bien no es claro si a partir de los genes *gap* es posible determinar el destino de cada célula o si son necesarios otros inputs, estos cálculos indican que los límites de transmisión de información en la regulación génica son significantes en la escala de información necesaria para el desarrollo embrionario, sugiriendo que la optimización de información tiene relevancia biológica.

Más aún, estos razonamientos fueron realizados a partir de la información mutua óptima, no es obvio que los sistemas biológicos operen en esos rangos. A partir de los datos experimentales [19], también es posible estimar la distribución conjunta $P(c; g)$ y así la información mutua, obteniéndose que $I_{data} = 1,5 \pm 0,15$ bits. Esto representa un $\sim 90\%$ del máximo teórico [36]. Es interesante señalar que transmitir más de un bit de información es relativamente difícil, y requiere acercarse a una correspondencia de las distribuciones óptima [35]. Esto implica que el embrión debe generar distribuciones de los niveles de expresión cuya estructura se asemeja a la óptima. Efectivamente, la distribución de los niveles de Hb están en buena concordancia con la predicha en el caso de que el sistema maximice el flujo de información, no sólo capturando la bimodalidad esperable en el sistema (donde Hb está expresado para la parte anterior del embrión y apagada en la posterior), sino que también captura los valores intermedios de expresión, expresados en alrededor del 20 % de los núcleos del embrión [36]. Esta distribución suave de los niveles de expresión contrasta con la visión usual del sistema Bcd/Hb como una forma de delimitar una frontera espacial nítida, para la cual bastaría una capacidad de un sólo bit. Sin embargo, la estimación de la información a partir de los datos muestran que es mayor a un bit, en cantidades muy cercanas al valor máximo posible. Esta información adicional depende de la estructura detallada de la distribución, la cual es predicha correctamente por la teoría (ver Fig. ??c).

Más precisamente, los niveles intermedios de Hunchback sólo pueden tener significado si el ruido en esos niveles de expresión es suficientemente bajo, y es precisamente esta condición intuitiva la que conduce a la concordancia predicha entre la distribución de niveles de expresión y los niveles de ruido. Estos detalles son importantes, porque es exactamente en este intervalo de concentraciones donde el embrión finalmente divide el eje antero-posterior con una precisión de una fila nuclear.

Este modelo, aunque sencillo, permite explorar e interpretar resultados en sistemas de relevancia como lo mencionado anteriormente. Diversos trabajos contemplaron otros modelos biofísicos que relajan algunos de los supuestos -como la aproximación de ruido pequeño- o bien incorporan otros elementos como más nodos o diversos motivos [45, 38, 44, 39].

Por ejemplo, en motivos más complejos, la transmisión de un único regulador a múltiples targets no interactuantes, $X \rightarrow (Y_1, Y_2, \dots, Y_M)$ tiene dos estrategias óptimas dependiendo de cuál es la fuente de ruido dominante, si es la que proviene del input o del output [38]. Si domina el ruido proveniente de la entrada, todos los targets deben tener la misma curva de dosis-respuesta al input, es decir perfectamente redundantes-. Esta solución es óptima porque permite promediar de la manera más efectiva el ruido de entrada (dominante), y la información $I(x; y)$ crece como $0,5\log_2(M)$ en el mejor de los casos. Es interesante marcar que la redundancia en redes biológicas comúnmente se explica a partir de la robustez evolutiva frente a mutaciones, mientras que en este marco emerge bajo limitaciones funda-

mentales del procesamiento de señales. En el caso de que el ruido del output aumente, se observa una transición de fase a una estrategia de mosaico: los M targets cubren un rango posible de inputs x , cada uno respondiendo con mayor sensibilidad en un régimen distinto de concentraciones de entrada, por lo que $I(x; y)$ puede crecer hasta un bit por gen.

Si se consideran otro tipo de motivos, por ejemplo una regulación tipo *feed-forward*, $X \rightarrow Y_1 \rightarrow Y_2 \rightarrow \dots \rightarrow Y_M$, nuevas estrategias óptimas son posibles. Si el input x activa targets y río abajo, el flujo de información no crece si la regulación es positiva (activación), ahora si alguna fuese negativa, es decir el gen y_i reprime al gen y_j , es posible aumentar el flujo de información, ya que abre el espacio de respuestas efectivas no monótonas de cada y frente a x .

Asimismo, al analizar la maximización del flujo de información en las células, es necesario considerar restricciones físicas, por ejemplo el costo energético asociado a la síntesis y degradación de moléculas [35], o bien la imposición de un número fijo de moléculas disponibles [38]. Al incorporar el costo metabólico de mantener dichas moléculas dentro del problema de optimización, la capacidad del canal queda acoplada al costo energético del sistema. Por ejemplo, un aumento en la cooperatividad de la regulación génica puede reducir el costo metabólico, aunque a expensas de incrementar la sensibilidad a fluctuaciones en la señal de entrada. Conocer el costo asociado a las moléculas interactuantes permitiría entonces deducir cuál es el nivel de cooperatividad óptima [35].

Resultados dinámicos

En muchos casos, los sistemas de interés responden en escalas temporales que son del mismo orden que las escalas en las que la señal de entrada también varía. Un ejemplo es provisto por los organismos que deben navegar en su entorno, dado que el *input* es moldeado por su respuesta durante la navegación [41]. Asimismo, la información del input puede estar codificada en su dinámica, como por ejemplo, en la quimiotaxis en bacterias, donde la concentración de las proteínas mensajeras intracelulares no dependen de la concentración actual del ligando, sino que responden a cambios en su concentración [5]. Es importante destacar que la capacidad de una red de procesamiento para responder de manera confiable a una señal depende no solo del valor instantáneo de la señal, sino también de la escala temporal en la que esta cambia. En general, las señales de entrada $X(t)$ y salida $Y(t)$ de las redes bioquímicas son señales continuas en el tiempo con tiempos de correlación no nulos.

Para entonces entender con qué fiabilidad las redes bioquímicas pueden transmitir información, es necesario conocer con qué precisión una señal de entrada en función del tiempo puede mapearse sobre una trayectoria de salida. Para ello es posible extender la definición de información mutua a trayectorias, para una red bioquímica en estado estacionario con una especie X con un número de copias X y una especie de salida Y con Y número de copias, considerando las señales de entrada y salida como las posibles trayectorias $X(t)$ y $Y(t)$:

$$M(X, Y) = \int \mathcal{D}X(t) \int \mathcal{D}Y(t) p(X(t), Y(t)) \log \frac{p(X(t), Y(t))}{p(X(t))p(Y(t))} \quad (7)$$

En general, calcular la información mutua entre trayectorias es una tarea compleja debido a la alta dimensionalidad del espacio de trayectorias. Una aproximación que vuelve el problema tratable es considerar un modelo Gaussiano [41, 42]. En este modelo, la dinámica de las especies químicas están descritas por la ecuación de Langevin bajo la aproximación lineal de ruido. En esta descripción, las trayectorias del sistema consisten en pequeñas desviaciones alrededor de una media macroscópica, siguiendo una estadística gaussiana; es decir que la distribución de las señales del input o del output para cualquier instante de tiempo es Gaussiana, así como también la distribución condicional entre dos puntos cualquiera. Esta aproximación permite tratar calcular la tasa de información mutua de

forma analítica y da una cota inferior para los sistemas que no satisfagan esta condición. Bajo esas aproximaciones, la distribución conjunta de las trayectorias discretizadas entre la señal de entrada y salida se puede describir mediante una Gaussiana multivariada:

$$p(\mathbf{v}) = \frac{1}{(2\pi)^N |Z|^{1/2}} \exp \left(-\frac{1}{2} \mathbf{v}^T \mathbf{Z}^{-1} \mathbf{v} \right) \quad (8)$$

donde el vector $\mathbf{v} = (\mathbf{x}, \mathbf{y})$ con $\mathbf{x} = (x(t_1), x(t_2), \dots, x(t_N))$ y $\mathbf{y} = (y(t_1), y(t_2), \dots, y(t_N))$; $x(t)$ e $y(t)$ son las desviaciones de X e Y de sus valores estacionarios, $\langle X \rangle$ e $\langle Y \rangle$. La matriz de covarianza $\mathbf{Z}$ tiene la forma:

$$\mathbf{Z} = \begin{pmatrix} C^{xx} & C^{yx} \\ C^{xy} & C^{yy} \end{pmatrix} \quad (9)$$

donde $C^{\alpha\beta}$ es una matriz de $N \times N$ con elementos $C_{ij}^{\alpha\beta} = C_{\alpha\beta}(t_i - t_j) = \langle \alpha(t_i) \beta(t_j) \rangle$. En el límite en que las señales son continuas en el tiempo, la tasa de información mutua $R(\mathbf{x}, \mathbf{y}) = \lim_{T \rightarrow \infty} M(\mathbf{x}, \mathbf{y})/T$ viene dada por:

$$R(\mathbf{x}, \mathbf{y}) = -\frac{1}{4\pi} \int_{-\infty}^{\infty} d\omega \ln \left[1 - \frac{|S_{yy}(\omega)|^2}{S_{xx}(\omega) S_{yy}(\omega)} \right] \quad (10)$$

donde el espectro de potencias $S_{\alpha\beta}(\omega)$ es la transformada de Fourier de $C_{\alpha\beta}(t)$. Al medir la señal de salida como función del tiempo, $R(\mathbf{x}, \mathbf{y})$ representa la tasa con la que aumenta en el tiempo la información acerca de la trayectoria de entrada; fundamentalmente, $R(\mathbf{x}, \mathbf{y})$ toma en consideración las correlaciones temporales de las señales de entrada y salida.

si consideramos que las redes bioquímicas no introducen correlaciones, podemos asumir que el espectro de potencias de la señal de salida $S_{yy}(\omega)$ estará dado por:


$$S_{yy}(\omega) = N(\omega) + g^2(\omega) S_{xx}(\omega) \quad (11)$$

donde $N(\omega)$ es el ruido intrínseco del proceso y $g^2(\omega) = |S_{xy}(\omega)|^2 / S_{xx}(\omega)^2$ es la relación ganancia-ruido dependiente de la frecuencia [41]. Identificando el espectro de potencias de la señal transmitida como $P(\omega) = g^2(\omega) S_{xx}(\omega)$, la eq. 2 puede reescribirse como:

$$R(\mathbf{x}, \mathbf{y}) = \frac{1}{4\pi} \int_{-\infty}^{\infty} d\omega \ln \left[1 + \frac{P(\omega)}{N(\omega)} \right]. \quad (12)$$


Es interesante señalar que, aún cuando la reacción de detección introduce correlaciones entre la señal de entrada y el ruido de la red, es posible definir la ganancia y espectro de la señal transmitida de la misma forma y definir R de esta manera, aunque N y g ya no serán propiedades intrínsecas de la red sino que también dependerán de la estadística de la señal de entrada.

A modo de ejemplo, consideremos el siguiente motivo, donde se tiene una señal X y un output Y :



Este es un modelo efectivo para reacciones enzimáticas o de activación génica, donde la reacción de unión entre la enzima y el sustrato o, respectivamente, la unión entre el factor de transcripción y el ADN, ya están integradas al modelo y no se consideran explícitamente. Este motivo obedece la ley de suma espectral (eq. 11), y del análisis se obtiene que: $g^2(\omega) = \frac{\nu^2}{\omega^2 + \mu^2}$ y $N(\omega) = \frac{2\nu \langle S \rangle}{\omega^2 + \mu^2}$, donde $\langle S \rangle = k/\lambda$. Como consecuencia de que las expresiones tienen la misma dependencia funcional con la frecuencia, la relación ganancia-ruido $g^2(\omega)/N(\omega)$, que determina con qué precisión una señal a una dada frecuencia puede ser transmitida, es independiente de ω por lo tanto puede transmitir señales de distintas frecuencias con la misma fidelidad.

En cambio si consideramos un modelo de unión reversible, por ejemplo un ligando y un receptor, descrito por:



En este caso, la señal de entrada es el número total de moléculas, tanto libres como en complejo, es decir $X_T(t) = X(t) + Y(t)$. Este motivo se comporta como un filtro pasa-bajo para la información. Específicamente

$$g^2(\omega) = \left[\frac{\nu(\mu + \nu + \lambda)}{\omega^2 + (\mu + \nu)^2 + \nu\lambda} \right]^2$$

y

$$N(\omega) = \frac{2\nu \langle S \rangle}{\omega^2 + (\mu + \nu)^2 + \nu\lambda}$$

por lo que la relación ganancia-ruido es aproximadamente constante para frecuencias bajas pero decae como ω^{-2} para frecuencias altas. Como las señales de entrada de las redes bioquímicas suelen detectarse a través de este motivo, este resultado sugiere que las componentes rápidas de la señal de entrada generalmente no se transmiten de forma confiable [41].

Un resultado interesante demostrado por Tostevin y ten Wolde [41] es que un circuito regulatorio para el cual la información instantánea es cero puede tener una tasa de información para las trayectorias grande. Por lo tanto, un circuito génico puede no transmitir información sobre la concentración a un dado tiempo, pero puede transmitir información sobre una ventana temporal.

Estos ejemplos muestran que la arquitectura de los motivos bioquímicos determina qué componentes temporales de la señal pueden transmitirse de manera confiable. En redes más complejas, la presencia de mecanismos de retroalimentación y auto-regulación puede modificar significativamente estas propiedades de filtrado y, por lo tanto, la transmisión de información. En particular, la retroalimentación puede mejorar la transmisión de información siempre y cuando ocurra río arriba de la fuente dominante de ruido en la cascada; si ocurre río abajo, tanto la ganancia como el ruido se ven afectados de manera similar, conservando aproximadamente la tasa de transmisión de información.

Asímismo, si se deben transmitir con precisión las señales sobre un amplio rango de frecuencias, la autoregulación positiva río arriba es ventajosa ya que aumenta la relación ganancia-ruido sobre todas las frecuencias. En cambio, si la célula sólo considera señales con frecuencias bajas o altas, será útil en términos de información, retroalimentaciones positivas o negativas [9]. Los motivos *feed-forward* pueden también modificar esta relación: tanto motivos coherentes o incoherentes puede funcionar con filtros pasa bajos o pasa altos de información, dependiendo de la intensidad del acoplamiento entre sus componentes [7]. La activación cooperativa de la salida mediante motivos tipo diamante pueden incrementar la relación ganancia-ruido, en términos de transmisión de información, es útil dividir la señal de entrada, transmitirla sobre rutas paralelas y recombinar las señales en la salida [7].

Más allá de la transmisión de información asociada a frecuencias individuales, las redes celulares también pueden utilizar la dinámica temporal como un grado de libertad adicional para codificar señales. En particular, señales oscilatorias pueden regular promotores génicos de manera eficiente e incluso generar respuestas más estables-en términos del ruido- que señales constantes equivalentes [40]. Asimismo, las señales oscilatorias pueden usarse para multiplexarse, es decir transmitir múltiples señales a través de una misma vía bioquímica con mínima interferencia, permitiendo respuestas específicas y robustas [8].

En esta dirección, Hahn, Walczak y Mora mostraron recientemente que múltiples mediciones temporales de la dinámica pueden combinarse de manera sinérgica, de modo que

la información obtenida a partir de una trayectoria completa puede exceder la suma de la información contenida en observaciones individuales [20]. En particular, demostraron que sistemas oscilatorios pueden exhibir fuerte sinergia temporal, indicando que las correlaciones dinámicas constituyen un componente fundamental de la codificación de información en redes bioquímicas

No obstante, estos resultados se obtienen dentro del régimen de aproximación lineal del ruido, donde las fluctuaciones se consideran gaussianas y las dinámicas se linealizan alrededor del estado estacionario. Si bien este enfoque permite derivar expresiones analíticas para la tasa de transmisión de información y estudiar cómo las redes filtran distintas frecuencias de la señal, muchas redes bioquímicas operan en regímenes donde las fluctuaciones discretas, las no linealidades y los eventos raros desempeñan un papel importante. En sí la regulación génica es un proceso altamente no lineal para la cual la aproximación de ruido lineal puede fallar. Por ejemplo, una distribución bimodal ya sea del input o del output (como en el caso de Bcd/Hb) no es compatible con esta aproximación: la media es una representación pobre de cualquiera de los dos estados, y la varianza va a ser mal aproximada alrededor de la media a partir de la expresión lineal.

En este contexto, trabajos recientes han extendido la noción de información mutua dinámica a trayectorias completas de procesos de Markov en tiempo continuo, permitiendo cuantificar la transmisión de información sin recurrir a aproximaciones gaussianas o espectrales [26]. El método desarrollado permite trabajar con sistemas con bajos números de moléculas y no linealidades. Los autores muestran que la tasa de información mutua I_t^{XY} puede descomponerse en términos de las entropías de transferencia $H_t^{X \rightarrow Y}$ y $H_t^{Y \rightarrow X}$. A diferencia de la información mutua, que por definición es simétrica, la entropía de transferencia proporciona información acerca del flujo de información dirigida en sistemas dinámicos.

Moor y Zechner estudian cómo se propaga la información a través de cascadas de reacciones químicas, encontrando que los procesos bioquímicos discretos presentan diferencias cuantitativas en incluso cualitativas cuando se los compara con procesos gaussianos equivalentes que poseen estadísticas de primer y segundo orden idénticas.

Fundamentalmente, estas diferencias parecen surgir de una noción distinta de trayectoria en cada una de estas dos situaciones: en los sistemas de estados discretos, una trayectoria contiene información detallada sobre los tipos de reacción y los instantes temporales. En la aproximación mediante procesos gaussianos, las fluctuaciones en el número de copias de una especie se representan de manera más gruesa como incrementos estocásticos efectivos a los que contribuyen múltiples reacciones. Dado que los eventos individuales ya no pueden resolverse de manera separada, esto introduce incertidumbre adicional y, en consecuencia, una pérdida de información.

A modo de ejemplo, estudian un sistema no lineal de tres nodos (A,B,C) con un *feedback* positivo, donde $A \rightarrow B \rightarrow C$ y C activa a A mediante una producción de tipo función de Hill que aumenta con la abundancia de C . El sistema presenta una biestabilidad para ciertos rangos de parámetros, donde las trayectorias individuales cambian estocásticamente entre dos modos. En el estacionario, para intensidades de la retroalimentación altas y bajas, el sistema tiene un solo modo, mientras que valores intermedios del parámetro que controla el feedback llevan al comportamiento bimodal. Al analizar la tasa de transmisión en el estacionario en función de este parámetro, los autores encuentran que el feedback positivo, con su biestabilidad resultante, puede maximizar la transmisión de información mutua entre el input y output. Al descomponer la información mutua en sus respectivas entropías de transferencia, encuentran que esta mejora se debe a un aumento en la contribución desde el output hacia el input, mientras que una contribución hacia adelante (del input al output) no se modifica ante una retroalimentación más potente. Tanto la tasa de transmisión de información como la tasa de entropía en el sentido de la retroalimentación $h^{C \rightarrow A}$ son máximas en el régimen bimodal, donde el sistema alterna aleatoriamente entre los dos

modos. Esto es un ejemplo de que el proceso de información en un sistema complejo y fuertemente no lineal está más allá de la teoría gaussiana.

En esta línea, se introduce la noción de descripciones de trayectorias basadas en reacciones o en estados. La aproximación gaussiana o de ruido lineal implica una descripción de las trayectorias del input y output basada en el estado de las mismas, mientras la información es transferida a través de las fluctuaciones en el número de copias o concentraciones. Sin embargo, la información de la entrada también está codificada en la secuencia de eventos de reacción de la salida. Las trayectorias discretas de los procesos Markovianos capturan esta codificación mediante los eventos de reacción, mientras que la aproximación gaussiana no. De hecho, las trayectorias discretas basadas en reacciones contienen más información que las correspondientes trayectorias continuas basadas en estados, lo que explica por qué el modelo gaussiano subestima significativamente la tasa para cualquier número de copias. Esta observación es la que conduce a una formulación alternativa de la aproximación lineal de ruido (LNA), la LNA basada en reacciones (RNLA), que es una descripción continua pero que registra explícitamente los eventos de reacción individuales [25].

En conjunto, estos resultados muestran que la transmisión de información en redes bioquímicas depende no sólo de la amplitud de las fluctuaciones, sino también de su estructura temporal y de la arquitectura de la red que las procesa. Distintos motivos regulatorios pueden actuar como filtros selectivos en frecuencia, favorecer la transmisión de determinadas escalas temporales o explotar correlaciones dinámicas para codificar información de manera más eficiente [9, 7]. En este sentido, la dinámica temporal emerge como un recurso fundamental para el procesamiento de señales celulares, aunque describir estos mecanismos más allá del régimen gaussiano y lineal continúa siendo un desafío abierto.

¿Hacia una teoría basada en principios?

El estudio de los sistemas biológicos desde la física busca entender cómo comportamientos funcionales complejos emergen a partir de interacciones moleculares intrínsecamente estocásticas. En este contexto, herramientas provenientes de la física estadística, la termodinámica fuera del equilibrio y la teoría de la información proporcionan un marco conceptual para formular preguntas cuantitativas acerca de cómo los sistemas vivos operan manteniendo flujos controlados de materia, energía e información. En particular, la teoría de la información ofrece un lenguaje natural para describir cómo las redes bioquímicas adquieren y transmiten información acerca de su entorno. Con el desarrollo de nuevas técnicas experimentales que permiten medir a célula única y con alta resolución temporal y espacial, es posible estimar flujos de información en sistemas reales. A estas escalas, los procesos de regulación y señalización operan lejos del equilibrio termodinámico, utilizando componentes discretos, fluctuantes y energéticamente costosos para detectar, transmitir y procesar señales de manera confiable. A pesar del progreso en el entendimiento del procesamiento de información a nivel biomolecular, aún hay trabajo por hacer. Un desafío es entender cómo funciona la transmisión de información en sistemas con resolución espacial donde los componentes químicos no están bien mezclados y los fenómenos de transporte desempeñan un papel importante.

Otro desafío, tanto teórico como experimental, es desarrollar descripciones cuantitativas completas de redes bioquímicas reales que incorporen simultáneamente fluctuaciones, costos energéticos, regulación y arquitectura de red, y contrastar luego sus predicciones con topologías y tasas de transmisión medidas experimentalmente.

En este contexto emerge una pregunta más general: si las redes bioquímicas operan bajo restricciones físicas fundamentales, ¿existen arquitecturas o regímenes dinámicos particularmente eficientes para transmitir información?

Una hipótesis que cautiva a la física, es que dentro de esas limitaciones fundamentales, existen regímenes operativos especiales y patrones de red de reacción donde se maximiza el flujo de información. La optimización como principio para realizar predicciones no triviales acerca del funcionamiento de sistemas biológicos fue aplicada con éxito en algunos casos, como en las tasas de crecimiento en redes metabólicas, flujos de materia en redes de transporte o incluso flujos de información en algunos circuitos regulatorios. Sin embargo, estos resultados están limitados a modelos que omiten muchas consideraciones biológicas o se focalizan en optimizar una única componente aislada en un sistema complejo.

Un objetivo más ambicioso es usar la optimización para derivar una teoría basada en principios, que permita hacer predicciones rigurosas para sistemas biológicos complejos y basado en múltiples componentes, donde las interacciones sean descritas con detalle molecular. Aún si estos ingredientes fueran suficientes, cómo deben ser combinados y cuál es justamente esa teoría? Una posibilidad es que las redes de reacciones bioquímicas en los organismos vivos evolucionaron para maximizar la transmisión de información entre entradas y salidas, sujetas tanto a restricciones fundamentales como a limitaciones de recursos (de tiempo, espacio, gasto energético, número de moléculas y especificidad de las interacciones moleculares). Aún así, si esta teoría puede formularse como un problema de optimización bajo restricciones, debería ser capaz de predecir parámetros desconocidos de la red, por ejemplo, tasas de reacción, a partir de restricciones empíricas de recursos -como el número de moléculas disponibles-, idealmente en un régimen en el que el número de restricciones, que deben ser medidas, sea mucho menor que el número de parámetros a predecir. Sin embargo, no es claro cómo proceder en casos donde sabemos por fundamentos teóricos que existe alguna restricción pero cuyo valor no podemos estimar directamente, por ejemplo el costo metabólico de producir una molécula de señalización. Otra desafío tiene que ver con la propia noción de optimización: explícita o implícitamente afirmamos que la optimización propuesta es el resultado de un proceso evolutivo, pero la evolución adaptativa también tiene sus propios límites fundamentales. Podría ser el caso de que la optimización evolutiva, de ser ese el principio, sea incompleta por estar aún en desarrollo. Aún así, una teoría basada en optimización puede ser predictiva. Una posible solución es, en lugar de trabajar con predicciones puntuales sobre un único sistema óptico, pensar en ensamblajes óptimos, es decir, distribuciones de resultados probables bajo la selección de fenotipos funcionales, como la alta transmisión de información [32].

Un ejemplo exitoso de la hipótesis de optimización, cuando se formula y restringe correctamente, puede predecir cuantitativamente el comportamiento de un sistema molecular complejo es provisto en Sokolowski et al. [32]. Los autores estudian la red de regulación de genes *gap* asociada al desarrollo embrionario en *Drosophila*. Específicamente, estiman los más de 50 parámetros de la red que maximicen la información posicional que los niveles locales de expresión génica proporcionan sobre la posición de una célula a lo largo del eje anterior-posterior del embrión. La optimización de la información está condicionada al fijar en número medio de moléculas (ARNm y proteínas) a los valores observados experimentalmente. Los autores encuentran ensamblajes de redes que les permite realizar predicciones cuantitativas sobre la distribución espacial de los genes, sus niveles de ruido, dinámicas e interacciones regulatorias que controlan esos patrones. Dentro de ese ensamblaje óptimo encuentran soluciones que se asemejan a las redes de los genes *gap* en todos estos aspectos. Asimismo, el maeco de optimización usado permite explorar la necesidad y suficiencia de distintos componentes de la red que aseguran la máxima transmisión de información, encontrando que cuatro genes son necesarios para patrones sin defectos y que la aparente redundancia entre los tres morfógenos maternos y la regulación cruzada de los genes *gap* desaparece bajo restricciones razonables sobre la fuerza de las interacciones regulatorias. Si bien este marco resulta elegante, no implica que la trayectoria evolutiva que condujo a la mosca actual haya seguido un proceso de optimización semejante al utilizado en el

modelo. Es importante destacar que estos dos puntos de vista no son incompatibles: múltiples rutas evolutivas podrían conducir hacia el mismo óptimo local. Este enfoque optimiza únicamente el contenido de información del patrón final, sin hacer afirmaciones sobre los estados intermedios por los que atraviesa un embrión individual. Asimismo, los resultados dependen tanto del indicador de aptitud propuesto, la información posicional, como del espacio de búsqueda considerado para encontrar soluciones óptimas. Aunque estas hipótesis parecen estar bien justificadas, la optimización numérica no equivale necesariamente a un proceso de adaptación evolutiva.

En esa dirección, también resulta importante distinguir entre maximizar la transmisión de información y maximizar la funcionalidad biológica global de una red regulatoria. Maximizar la transmisión de información no equivale necesariamente a maximizar la capacidad computacional o funcional de una red biológica. Los organismos no sólo deben transmitir señales con precisión, sino también tomar decisiones relevantes para su supervivencia, integrar información proveniente de múltiples fuentes y responder en tiempos adecuados bajo restricciones metabólicas y evolutivas. Por lo tanto, entender cómo los sistemas biológicos balancean transmisión de información, procesamiento dinámico y costo físico continúa siendo uno de los principales desafíos en la interfaz entre física estadística, teoría de la información y biología de sistemas.

No es obvio que el flujo de información sea optimizado cuando no es el fenotipo bajo presión adaptativa, sino características más concretas y específicas. Si no todos los bits son igualmente costosos ni igualmente predictivos [34], tampoco es claro que el sistema que optimiza, bajo alguna restricción de recursos, un dado fenotipo sea la misma que maximiza la transmisión de información. A su vez, aunque la información del estímulo es medida en bits, estos codifican distintas características del estímulo y dichas características pueden no tener el mismo valor adaptativo para el organismo.

En última instancia, uno esperaría que un sistema óptimo de procesamiento de información sea aquel que preserve sólo los bits relevantes, presumiblemente aquellos que son predictivos respecto de estados futuros del entorno y pueda así orientar su comportamiento o toma de decisiones. Si es así, con sólo maximizar la información no alcanza, ya que la transmisión no es computación. Entonces, la transmisión y la representación confiable de información son necesarias, pero no suficientes, para una teoría plenamente desarrollada.

De forma prometedora, existen diversos marcos teóricos que vinculan la confiabilidad de las representaciones internas -asociado a la teoría de la información- con límites sobre el desempeño alcanzable guiado por tales representaciones. Si la misma es ruidosa y poco confiable, los comportamientos celulares basados en dichas representaciones estarán desajustados y posiblemente no estarán bien adaptados al entorno, por lo que pueden ser seleccionados negativamente. A la inversa, la presión selectiva debería impulsar la optimización de la transmisión dentro de las restricciones de recursos, al menos hasta que deje de limitar el desempeño adaptativo. Otra conexión interesante aparece en el campo de la teoría de control, que destaca tanto los beneficios así como las limitaciones para aplicar paradigmas de control a contextos biológicos, donde el sensado, la transmisión, la computación y luego la acción que ejecute el organismo estarán todas limitadas en velocidad y precisión debido a restricciones fundamentales.

Aún con todas estas consideraciones, el estudio de la biología en su escala molecular desde la lente de la física ha sido fructífera. Es probable que las predicciones de una teoría emergente basada en la optimización con restricciones no sea única ni que los sistemas que observamos estén diseñados en el óptimo, por lo que es necesario el desarrollo de nuevas herramientas estadísticas para conectar las predicciones teóricas con medidas parcialmente incompletas de los estados de las redes de alta dimensionalidad.

Referencias

- [1] Uri Alon. An Introduction to Systems Biology; Design Principles of Biological Circuits; Second Edition. Technical report, 2019.
- [2] H.C. Berg and E.M. Purcell. Physics of chemoreception. *Biophysical Journal*, 20(2):193–219, 11 1977.
- [3] William Bialek and Sima Setayeshgar. Physical limits to biochemical signaling. Technical report, 2005.
- [4] William J. Blake, Mads Kærn, Charles R. Cantor, and J. J. Collins. Noise in eukaryotic gene expression. *Nature*, 422(6932):633–637, 4 2003.
- [5] S M Block, J E Segall, and H C Berg. Adaptation kinetics in bacterial chemotaxis. *Journal of Bacteriology*, 154(1):312–323, 4 1983.
- [6] Clive G. Bowsher and Peter S. Swain. Environmental sensing, information transfer, and cellular decision-making, 2014.
- [7] W. H. de Ronde, F. Tostevin, and P. R. ten Wolde. Feed-forward loops and diamond motifs lead to tunable transmission of information in the frequency domain. *Physical Review E*, 86(2):021913, 8 2012.
- [8] Wiet De Ronde and Pieter Rein Ten Wolde. Multiplexing oscillatory biochemical signals. *Physical Biology*, 11(2), 2014.
- [9] Wiet Hendrik De Ronde, Filipe Tostevin, and Pieter Rein Ten Wolde. Effect of feedback on the fidelity of information transmission of time-varying signals. *Physical Review E - Statistical, Nonlinear, and Soft Matter Physics*, 82(3), 9 2010.
- [10] Michael B. Elowitz, Arnold J. Levine, Eric D. Siggia, and Peter S. Swain. Stochastic Gene Expression in a Single Cell. *Science*, 297(5584):1183–1186, 8 2002.
- [11] Robert G. Endres and Ned S. Wingreen. Maximum Likelihood and the Single Receptor. *Physical Review Letters*, 103(15):158101, 10 2009.
- [12] Tamar Friedlander, Roshan Prizak, Nicholas H. Barton, and Gašper Tkačik. Evolution of new regulatory functions on biophysically realistic fitness landscapes. *Nature Communications*, 8(1):216, 8 2017.
- [13] Tamar Friedlander, Roshan Prizak, Calin C Guet, Nicholas H. Barton, and Gasper Tkacik. Intrinsic limits to gene regulation by global crosstalk. *Nat. Commun.*, (7):12307, 2015.
- [14] Daniel T Gillespie. A General Method for Numerically Simulating the Stochastic Time Evolution of Coupled Chemical Reactions. Technical report, 1976.
- [15] Christopher C. Govern and Pieter Rein Ten Wolde. Fundamental limits on sensing chemical concentrations with linear biochemical networks. *Physical Review Letters*, 109(21), 11 2012.
- [16] Christopher C. Govern and Pieter Rein Ten Wolde. Energy dissipation and noise correlations in biochemical sensing. *Physical Review Letters*, 113(25), 12 2014.
- [17] Christopher C. Govern and Pieter Rein ten Wolde. Optimal resource allocation in cellular sensing systems. *Proceedings of the National Academy of Sciences*, 111(49):17486–17491, 12 2014.

- [18] Rok Grah, Benjamin Zoller, and Gašper Tkačik. Nonequilibrium models of optimal enhancer function. 117:31614–31622, 2020.
- [19] Thomas Gregor, David W. Tank, Eric F. Wieschaus, and William Bialek. Probing the Limits to Positional Information. *Cell*, 130(1):153–164, 7 2007.
- [20] Lauritz Hahn, Aleksandra M. Walczak, and Thierry Mora. Dynamical Information Synergy in Biochemical Signaling Networks. *Physical Review Letters*, 131(12), 9 2023.
- [21] J J Hopfield. Kinetic Proofreading: A New Mechanism for Reducing Errors in Biosynthetic Processes Requiring High Specificity. *Proceedings of the National Academy of Sciences*, 71(10):4135–4139, 1974.
- [22] Kazunari Kaizu, Wiet de Ronde, Joris Paijmans, Koichi Takahashi, Filipe Tostevin, and Pieter Rein ten Wolde. The Berg-Purcell Limit Revisited. *Biophysical Journal*, 106(4):976–985, 2 2014.
- [23] R Landauer. Irreversibility and Heat Generation in the Computing Process. *IBM Journal of Research and Development*, 5(3):183–191, 1961.
- [24] Hanbin Mao, Paul S. Cremer, and Michael D. Manson. A sensitive, versatile microfluidic assay for bacterial chemotaxis. *Proceedings of the National Academy of Sciences*, 100(9):5449–5454, 4 2003.
- [25] Anne-Lena Moor, Age Tjalma, Manuel Reinhardt, Pieter Rein ten Wolde, and Christoph Zechner. State- versus Reaction-Based Information Processing in Biochemical Networks. 5 2025.
- [26] Anne Lena Moor and Christoph Zechner. Dynamic information transfer in stochastic biochemical networks. *Physical Review Research*, 5(1), 1 2023.
- [27] Thierry Mora and Ned S. Wingreen. Limits of Sensing Temporal Concentration Changes by Single Cells. *Physical Review Letters*, 104(24):248101, 6 2010.
- [28] Thomas E. Ouldridge, Christopher C. Govern, and Pieter Rein ten Wolde. Thermodynamics of Computational Copying in Biochemical Systems. *Physical Review X*, 7(2):021004, 4 2017.
- [29] Thomas E. Ouldridge and Pieter Rein ten Wolde. Fundamental Costs in the Production and Destruction of Persistent Polymer Copies. *Physical Review Letters*, 118(15):158103, 4 2017.
- [30] Mindy Liu Perkins, Justin Crocker, and Gašper Tkačik. Chromatin enables precise and scalable gene regulation with factors of limited specificity. *Proceedings of the National Academy of Sciences of the United States of America*, 122(1):e2411887121, 1 2025.
- [31] J E Segall. Polarization of yeast cells in spatial gradients of alpha mating factor. *Proceedings of the National Academy of Sciences*, 90(18):8332–8336, 9 1993.
- [32] Thomas R Sokolowski, Thomas Gregor, William Bialek, Gašper Tkačik, by B Dmitri Chklovskii, Angela H DePace, Michael M Desai, and Jane Kondev. Deriving a genetic regulatory network from an optimization principle. 122(1), 2025.
- [33] Peter S. Swain, Michael B. Elowitz, and Eric D. Siggia. Intrinsic and extrinsic contributions to stochasticity in gene expression. *Proceedings of the National Academy of Sciences*, 99(20):12795–12800, 10 2002.

- [34] Age J. Tjalma, Vahe Galstyan, Jeroen Goedhart, Lotte Slim, Nils B. Becker, and Pieter Rein ten Wolde. Trade-offs between cost and information in cellular prediction. *Proceedings of the National Academy of Sciences*, 120(41), 10 2023.
- [35] Gašper Tkačik, Curtis G. Callan, and William Bialek. Information capacity of genetic regulatory elements. *Physical Review E - Statistical, Nonlinear, and Soft Matter Physics*, 78(1), 7 2008.
- [36] Gašper Tkačik, Curtis G. Callan, William Bialek, and Joseph Henry. Information flow and optimization in transcriptional regulation. Technical report, 2008.
- [37] Gašper Tkačik and Pieter Rein Ten Wolde. Information Processing in Biochemical Networks. *Annual Review of Biophysics Downloaded from www.annualreviews.org. MINCYT Master Account*, 17:36, 2025.
- [38] Gašper Tkačik, Aleksandra M. Walczak, and William Bialek. Optimizing information flow in small genetic networks. *Physical Review E - Statistical, Nonlinear, and Soft Matter Physics*, 80(3), 9 2009.
- [39] Gašper Tkačik, Aleksandra M. Walczak, and William Bialek. Optimizing information flow in small genetic networks. III. A self-interacting gene. *Physical Review E*, 85(4):041903, 4 2012.
- [40] Filipe Tostevin, Wiet De Ronde, and Pieter Rein Ten Wolde. Reliability of frequency and amplitude decoding in gene regulation. *Physical Review Letters*, 108(10), 3 2012.
- [41] Filipe Tostevin and Pieter Rein ten Wolde. Mutual Information between Input and Output Trajectories of Biochemical Networks. *Physical Review Letters*, 102(21):218101, 5 2009.
- [42] Filipe Tostevin and Pieter Rein Ten Wolde. Mutual information in time-varying biochemical systems. *Physical Review E - Statistical, Nonlinear, and Soft Matter Physics*, 81(6), 6 2010.
- [43] Van Kampen NG. *Stochastic Processes in Physics and Chemistry*, volume 1. Elsevier, Amsterdam, 2007.
- [44] Aleksandra M. Walczak, Gašper Tkačik, and William Bialek. Optimizing information flow in small genetic networks. II. Feed-forward interactions. *Physical Review E*, 81(4):041905, 4 2010.
- [45] Eytan Ziv, Ilya Nemenman, and Chris H. Wiggins. Optimal signal processing in small stochastic biochemical networks. *PLoS ONE*, 2(10), 10 2007.
- [46] Benjamin Zoller, Thomas Gregor, and Gašper Tkačik. Eukaryotic gene regulation at equilibrium, or non?, 9 2022.




Figura 1: **Regulación transcripcional de la expresión génica.** **a.** La ocupación de los sitios de unión en el ADN por los factores de transcripción definen la actividad del promotor y en consecuencia, los niveles de proteína producidos. La física de la interacción entre el factor y el ADN, los procesos de transcripción y traducción determinan la distribución de probabilidad condicional de los niveles de expresión g dada una concentración c del factor de transcripción $P(g|c)$, mostrado como un mapa de color con rojo (azul) a probabilidad alta (baja). La línea blanca representa media en la relación entre el input/output y la línea discontinua indica $\pm$ SD del ruido alrededor de la media. Dos distribuciones del input $P_{TF}(c)$ se pasan a través de $P(g|c)$ para producir dos distribuciones del output $p_{exp}(g)$. **b.** *Der.* Relación entre Bcd (input) y Hb (output) medidos en el embrión de *Drosophila*. Cada punto representa las concentraciones medidas en un núcleo celular único. Los niveles g de Hb está normalizados, las concentraciones c de Bcd están escaladas por la constante K_d -la concentración de Bcd para la cual el nivel de Hb es la mitad del máximo-. *Izq.* Desviación estandar del ruido en los niveles de Hb en función de la concentración de Bcd; las barras de error representan $\pm 1SD$ a través de los embriones. [19] **c.** Distribuciones de los niveles de expresión medidas (negro) y óptimas (rojo) para Hunchback. Figura adaptada de [36].